

Groupe: 4A IAD Groupe 1

Edouard NADAUD Guilhem NESPOULOUS Aymeric NOBLANC

1. Définir un modèle additif avec:

- une tendance quadratique (c'est-à-dire du type  $at^2 + bt + c$ )
- une composante saisonnière fonction périodique de période 4
- une erreur de type bruit blanc gaussien Pour simuler une série temporelle trimestrielle débutant au deuxième trimestre 1986 et finissant au premier trimestre 2001. Nous choisirons les différents paramètres du modèle : coefficients de la tendance (a, b et c), expression de la saisonnalité et écart-type du bruit blanc).

$$(at^2 + bt + c) + \cos(2\pi(t/4 - 1986)) + \varepsilon_t$$

commence au 2eme semestre 1986 soit avril 1986 fin premier semestre 2001 soit janvier 2001 \* Nombre de mois =  $1312 + 9 = 165$ , *notre bruit gaussien fait aller de 1 a 165 de même pour nos données ( 167), on choisit un écart type de 1*

```
Modele additif  $X_t = Z_t + S_t + \varepsilon_t$ 
```

```
Z_t = (0.0001 * i^2 + 0.04 * i + 2)
S_t = cos(2 * pi * ((i/4) - 1986))
ε_t = erreur[i]
```

```
data=array()
pi=3.14
nbrmonth=167
erreur<-rnorm(nbrmonth,sd=1,mean=0)
```

On choisit  $a=0.0001$   $b=0.04$   $c=2$

Creation de notre serie temporelle numérique

```
for (i in 1:nbrmonth){
  data[i]= (0.0001*i^2+0.04*i+2)+cos(2*pi*((i/4) - 1986))+erreur[i]
}
```


On fait commencer notre serie temporelle au mois de mars 1986

```
data<-as.ts(data)

data<-ts(data,start=c(1986,3),frequency=4)
```

Affichage de notre serie temporelle


```
ts.plot(data)
```



2. Afficher les différentes composantes. Tracer la tendance, la saisonnalité, le bruit ainsi que la série chronologique obtenue.

```
data.dcp= decompose(data,type="additive")  
plot(data.dcp)
```


## Decomposition of additive time series



```
help(decompose)
```


Pour estimer la tendance nous allons calculer nos moyennes mobiles qui seront un bon estimateur de la tendance (avec le bruit en plus)

```
filt<-rep(1/4,3)
filt<-(c(1/8,filt,1/8))
Z<-filter(data,filter=filt,sides=2)
Z<-ts(Z,start=c(1986,3),frequency=4)
ts.plot(Z)
```



Nous allons maintenant obtenir la saisonalité pour cela nous faisons nos data moins la tendance et le bruit gaussien ( Z )

```
S<-data-Z  
s<-tapply(S,cycle(S),mean,na.rm=T)  
s<-s-mean(s)  
plot(s)
```




3. Superposer les séries annuelles des années 1987 à 2000.

```
ts.plot(matrix(window(data,1986,c(1999,12)),12))
```

```
## Warning in window.default(x, ...): 'start' value not changed
```

```
## Warning in matrix(window(data, 1986, c(1999, 12)), 12): la longueur des données  
## [62] n'est pas un diviseur ni un multiple du nombre de lignes [12]
```



4. Extraire une sous série commençant au deuxième trimestre 1989 et finissant au troisième trimestre 1991.

```
Xdata=window(data,start=c(1989,4),end=c(1991,9))  
plot(Xdata)
```

Groupe: 4A IAD Groupe 1

Edouard NADAUD Guilhem NESPOULOUS Aymeric NOBLANC


Exercice : à rendre pour le dimanche 7 mars 2021 à 23h30 Simuler une série chronologique  $(Y_t)_{t=1, \dots, 100}$  suivant le modèle  $Y_t = 0,01t + 1 + 2 \sin(2\pi t/5) + \epsilon_t$ , où  $(\epsilon_t)_t$  est un bruit blanc gaussien de variance  $1/100$ .

```
data=array()
erreur<-rnorm(100,sd=1/10,mean=0)
```

```
for (i in 1:100){
  data[i]= (0.01*i)+1+(2*sin((2*pi*i)/5) )+ erreur[i]
}
```

On affiche notre serie temporelle


```
data<-as.ts(data)
data<-ts(data,start=2000,frequency=5)
ts.plot(data)
```



Déterminer la tendance, la saisonnalité (période) de cette série chronologique. Les tracer.

```
data.dcp= decompose(data,type="add")
plot(data.dcp)
```

## Decomposition of additive time series



Notre serie temporelle est un modele aditif de forme

Modele additif  $X_t = Z_t + S_t + \varepsilon_t$

$Z_t = (0.01 * i) + 1$

$S_t = (2 * \sin((2 * \pi * i) / 5))$


$\varepsilon_t = \text{erreur}[i]$

Notre  $S_t$  est une fonction de periode 5 nous avons donc une saisonnalité de 5. Notre  $Z_t$  est une fonction affine de coefficient directeur 0.01, notre tendance sera donc croissante. Néanmoins le coefficient directeur étant très faible la fonction aura une croissance extrêmement faible et donc une tendance plutôt constante.

Utiliser la méthode des moyennes mobiles ci-dessus pour éliminer la saisonnalité puis estimer les coefficients du saisonnier.



```
filt<-rep(1/5,5)
Z<-filter(data,filter=filt,sides=2)
Z<-ts(Z,start=2000,frequency=5)
ts.plot(Z)
```




Estimation de la composante saisonnière S la saisonnalité

```
S<-data-Z
```

Estimation c des coefficients du saisonnier Série corrigée des variations saisonnières Voici la saisonnalité sur une période 5

```
s<-tapply(S,cycle(S),mean,na.rm=T)
s<-s-mean(s)
plot(s)
```



```
CVS<-matrix(1,20,5)
```


Calcul de XCV  $S = X - S$

Nous avons 5 données par an su 20 ans


```
for (i in 1 :20) {
  for (j in 1 :5) {
    CVS[i,j]=t(matrix(data,5,20))[i,j]-s[j]
  }
}
```

```
CVS=as.vector(t(CVS))
CVS=as.ts(CVS)
CVS=ts(CVS,start=2000,frequency=5)
```

```
ts.plot(data)
```



```
ts.plot(CVS)
```



coefficient saisonnier

s

##	1	2	3	4	5
##	1.87612091	1.21281802	-1.19676170	-1.91701991	0.02484268

Utiliser une régression linéaire par moindres carrés pour estimer les coefficients de la tendance.

```
y=time(CVS)
CVS.lm=lm(CVS~y)
CVS.lm$coefficient
```

##	(Intercept)	y
##	-102.97832740	0.05198707

Comparer les estimateurs avec les vrais coefficients.

yreel=0.01 ycalculé=0.05

Coefficient reel : 1.903555650 1.156133321 -1.155990654 -1.895566966 -0.008131351 trouvé 1.902113  
1.175571 -1.175571 -1.902113 -4.898587e-16

```
for (i in 1 :5) {
  print(2*sin((2*pi*i)/5))
}
```


```
## [1] 1.902113
## [1] 1.175571
## [1] -1.175571
## [1] -1.902113
## [1] -4.898587e-16
```

Proposer une prévision à l'horizon 3.

```
X1=rep(1,15)
for (i in 1:15)
  {X1[i]=-102.44482083+0.05170816*(2020+5%%1+(i-1)/5) +s[i%%5+1]}

X2=c(as.vector(data),X1)


X2=as.ts(X2)
X2=ts(X2,start=2000,frequency=5)
plot(X2)
```



Analyser les résidus. Les représenter.


```
res=CVS-CVS.lm$fitted.values  
res=res/sqrt(var(res))  
acf(res)
```

### Series res




```
hist(res)
```

## Histogram of res



```
qqnorm(res)
abline(0,1)
```

## Normal Q-Q Plot




Appliquer la fonction `decompose` et comparer avec les vraies valeurs.

```
data.dcp= decompose(data,type="add")  
plot(data.dcp)
```




## Decomposition of additive time series




comparaison de la tendance decompose versus reel Nous pouvons remarqué que les valeurs réelle sont pratiquement identique aux valeurs estimée de decompose

```
plot(data.dcp$trend)
```



```
plot(z)
```




comparaison de la saisonalité décomposée versus réel Nous pouvons remarquer que les valeurs réelles sont identiques aux valeurs estimées de décomposition

```
if(sum(data.dcp$figure==s)==length(s)){  
  print("les valeurs sont identiques")  
}
```

```
## [1] "les valeurs sont identiques"
```

```
plot(data.dcp$figure)
```



```
plot(s)
```

